

# Predicción de la irradiación solar a corto plazo utilizando imágenes de cielo abierto recopiladas en la planta fotovoltaica El Paso de la empresa Enel

Daniela Andrea Ruiz Lopez  
Universidad de los Andes  
Bogotá, Colombia

da.ruizl1@uniandes.edu.co

Alejandra Tabares Pozos  
Universidad de los Andes  
Bogotá, Colombia

a.taparesp@uniandes.edu.co

## Abstract

*La transición a un sistema energético renovable se ha convertido en una necesidad imperativa para combatir el cambio climático. La energía solar juega un papel fundamental en esta transición, pero su incorporación en la matriz energética de los países aun se ve limitada por el desafío que supone la predicción de irradiación solar. Esta investigación presenta un modelo de aprendizaje automático diseñado para abordar este reto, utilizando imágenes de cielo abierto y datos atmosféricos tomados cada 30 segundos por el dispositivo Sky InSight™ ubicado en la planta "El Paso" de la empresa Enel en Colombia. El estudio propone un modelo híbrido que combina Redes Neuronales Convolucionales (CNN) con Redes Neuronales Artificiales (ANN) para la predicción de irradiación solar a corto plazo. A través de una meticulosa evaluación de distintas configuraciones de red e hiperparámetros, así como de técnicas de preprocesamiento de imágenes y datos, el modelo alcanzó un Error Cuadrático Medio (MSE) de 0.0069, demostrando su eficacia. Este trabajo no solo subraya la viabilidad de nuestro enfoque para la predicción de irradiación solar, sino que también resalta su potencial para mejorar la gestión de energía solar y contribuir a una transición energética sostenible.*

## 1. Introducción

El cambio climático se ha establecido firmemente como uno de los desafíos más críticos de nuestra era, con impactos profundos y de amplio alcance, como el incremento en la frecuencia e intensidad de fenómenos meteorológicos extremos, la elevación del nivel del mar, la reducción de tierras aptas para la agricultura, la escasez de alimentos, la reestructuración de los patrones de recursos hídricos y pérdida de biodiversidad [13]. Crucialmente, se ha identificado que una proporción significativa de las emisiones de gases de efecto invernadero, responsables del cambio

climático, se originan en el sector energético, predominando las emisiones resultantes de la combustión de combustibles fósiles [13]. Esta conexión directa entre la generación de energía y el cambio climático destaca la necesidad de una transformación radical en la manera en que producimos y consumimos energía, de manera que la transición hacia las energías renovables y la eficiencia energética se ha convertido en una necesidad imperativa. De hecho, para el año 2019, estas estrategias ya representaban el 94% de las reducciones de emisiones de gases de efecto invernadero [5].

La energía solar es uno de los componentes más importantes en la transición a un sistema energético renovable [5], por lo que los sistemas fotovoltaicos para la generación de energía son cada vez más populares. Sin embargo, la optimización del rendimiento de los sistemas fotovoltaicos depende críticamente de la precisión en la predicción de la radiación solar a corto plazo, tarea que presenta desafíos significativos debido a la variabilidad y la naturaleza impredecible del clima. Factores como la cobertura de nubes en constante cambio, las condiciones atmosféricas fluctuantes y las limitaciones de los modelos de predicción actuales, que a menudo se basan en datos históricos y no pueden adaptarse rápidamente a las condiciones meteorológicas cambiantes, contribuyen a la incertidumbre. Además, la integración de datos variados y la calidad de estos datos pueden limitar la efectividad de los pronósticos.

El estado del arte del pronóstico de irradiación solar a corto plazo está avanzando rápidamente gracias a los avances en la tecnología de observación satelital, la modelización numérica y el aprendizaje automático. Actualmente existen varios métodos para pronosticar la radiación solar a corto plazo, incluidos métodos estadísticos, modelos numéricos de predicción meteorológica y enfoques de aprendizaje automático. Los métodos estadísticos, como el pronóstico de persistencia y los modelos de promedio móvil integrado autorregresivo (ARIMA), utilizan datos históricos para hacer predicciones sobre la radiación solar futura. Los modelos numéricos de predicción del clima,

como el Sistema de pronóstico global (GFS), utilizan modelos matemáticos complejos para simular el clima y predecir la irradiación solar futura en función de las condiciones climáticas actuales. Los enfoques de aprendizaje automático, como las redes neuronales artificiales y la regresión de vectores de soporte, usan patrones en datos históricos para hacer predicciones sobre la radiación solar futura.

Uno de los acercamientos al pronóstico de irradiación solar más utilizados es el basado en imágenes de cielo. Estas imágenes son adecuadas para pronósticos a muy corto plazo en un solo lugar o en lugares cercanos, dada su alta resolución temporal (de segundos a minutos) y espacial [8]. Esta técnica ha tomado más fuerza desde el 2011 y ha evolucionado desde el uso de características extraídas de las imágenes para construir modelos físicos deterministas o de aprendizaje automático, hacia la adopción de técnicas de visión por computadora en los últimos cinco años [8]. Este enfoque usa modelos de aprendizaje profundo basados en secuencias históricas de imágenes del cielo, utilizando principalmente redes neuronales convolucionales (CNNs) y, en algunos casos, combinadas con redes neuronales recurrentes como LSTM. Estos modelos representan el estado del arte en predicción solar, aunque aún presentan limitaciones en su capacidad predictiva a largo plazo.

El enfoque más común para el pronóstico de la irradiación solar con imágenes de cielo, es la integración de una red neuronal convolucional para la extracción de características de las imágenes y una red neuronal artificial para tratar los datos auxiliares disponibles (como mediciones de irradiancia pasadas, posición angular del sol, temperatura, humedad, etc). Ambas salidas se introducen en otra red neuronal que las integra para dar su predicción final [9].

Actualmente, las redes LTSM (Long Short-Term Memory) han aumentado su popularidad en el pronóstico de la irradiancia solar debido a que son un tipo de red neuronal recurrente que preserva los datos para uso futuro y revela las relaciones a largo plazo entre series temporales. De esta manera, se han propuesto modelos híbridos, como [14] que integran una red LSTM con una CNN para extraer características espaciales y características temporales de manera separada y finalmente fusionarlas para predecir la irradiancia horizontal global con una hora de anticipación. De manera similar, [7] presentó el uso de LSTM y RNN y [4] diseñó un modelo de predicción híbrido denominado SCLC que integra algoritmo Slime-Mould, una CNN, una red LSTM y una CNN final con salida de perceptrón multicapa para la selección de características. Otros acercamientos como el de [15] han utilizado el mecanismo de atención integrado a las redes LSTM para la previsión de energía fotovoltaica a corto plazo.

Tras discutir la importancia de la energía solar en el contexto del cambio climático y los desafíos inherentes a

la predicción precisa de la irradiación solar, es pertinente examinar cómo estas consideraciones se aplican en situaciones del mundo real. Un ejemplo ilustrativo es Enel, el productor y distribuidor de energía eléctrica y gas con mayor cubrimiento en Colombia (25%), que atiende a más de 3.4 millones de clientes en Bogotá [2]. Enel reconoce la relevancia de las energías renovables y la importancia de predecir la cantidad de energía solar esperada a corto plazo con precisión para adaptar adecuadamente la producción de energía, maximizar la eficiencia de sus instalaciones solares y reducir costos operativos. Sin embargo, a pesar de contar con recursos como datos obtenidos directamente en sus instalaciones (cámara in situ), imágenes satelitales y valiosa información meteorológica, Enel aún se enfrenta al reto de desarrollar un método eficaz y preciso para el pronóstico de la irradiación solar.

En consecuencia, esta investigación propone desarrollar un modelo de aprendizaje automático que utilice las observaciones del cielo abierto y datos atmosféricos tomados cada 30 segundos por la cámara de cielo abierto ubicada en la planta de Enel. Este modelo hará parte de un sistema de pronóstico integral que combine datos de series de tiempo e imágenes satelitales para ofrecer predicciones más precisas y confiables de la irradiación solar. Al ofrecer una comprensión completa de las condiciones atmosféricas, este sistema proporcionará información valiosa a los productores de energía solar, ayudándoles a maximizar su producción y asegurar una integración eficaz en la red eléctrica. Este proyecto no solo mejorará la gestión de los sistemas fotovoltaicos de Enel, sino que también contribuiría al objetivo más amplio de fomentar un futuro energético sostenible.

## 2. Metodología

### 2.1. Datos

Los datos utilizados para este estudio fueron proporcionados por la empresa Enel, por lo que son datos privados y de uso restringido. Estos datos fueron tomados en la planta fotovoltaica "El Paso" que se encuentra ubicada en el departamento de Cesar, al norte de Colombia. Esta instalación se extiende sobre aproximadamente 210 hectáreas y está equipada con cerca de 250.000 paneles solares, siendo la más grande hasta la fecha y representando un significativo 80% de la capacidad solar total del país [3]. El paso tiene la capacidad de satisfacer las necesidades energéticas de unos 102.000 hogares colombianos, lo que subraya su importancia tanto en términos de producción energética como de aplicación en investigaciones de predicción de irradiación solar.

Las imágenes de cielo abierto fueron tomadas con un dispositivo Sky InSight™, el cual es un avanzado sistema de generación de imágenes infrarrojas del cielo creado por Reuniwatt, que se especializa en la observación y predicción

de la nebulosidad [10]. El dispositivo recoge datos ultralocales de nubes en un ángulo de 180°, alcanzando aproximadamente 2 km a la redonda. Además, incorpora un sensor de irradiación solar, un termómetro y un sensor de humedad. Las imágenes originales se encuentran en el espacio de color sRGB y manejan datos de tipo uint16. Sus dimensiones originales son de (480, 640), es decir, no cuentan con canales de color (Ver figura 1).




Figure 1. Ejemplo de las imágenes de cielo originales

En cuanto a la cantidad de datos disponibles, se cuenta con datos tomados entre las 5 de la mañana (5:00am) y las siete de la noche (7:00pm) cada 30 segundos para 5 días del mes de agosto de 2023. Sin embargo, la información numérica de fecha y hora de captura, temperatura, humedad e irradiancia (GHI), fue tomada cada minuto para dichos días en la totalidad del transcurso del día. En consecuencia, se conformó una base de datos con solo aquellos datos para los cuales se contaba con la información visual y meteorológica, reduciendo así los datos a un total de 4180 muestras.




Figure 2. Radiación Solar Horizontal (GHI) entre las 5:00am y 7:00pm del día 22 de Agosto de 2023

En la tabla 1 se muestran algunas estadísticas descriptivas como la cantidad de datos, el promedio, la desviación estándar, el mínimo y el máximo para cada una de las variables numéricas.

Table 1. Estadísticas descriptivas de los datos numéricos

	Temperatura	Humedad	GHI
Conteo	4180	4180	4180
Promedio	32.57	67.13	91.48
Desviación Estándar	4.87	19.13	66.68
Valor mínimo	24	35.52	0.15
Valor máximo	41.98	99.2	226.43

## 2.2. Metodología de evaluación

En el campo del aprendizaje automático, la selección de una métrica de rendimiento adecuada es fundamental para evaluar y guiar el desarrollo de modelos predictivos. Para nuestra tarea específica, hemos optado por el Error Cuadrático Medio (MSE) [1] como la métrica primaria de evaluación. La elección de MSE está fundamentada en su capacidad para resaltar errores significativos, la claridad en su interpretación y su amplio uso en el campo, lo cual establece una base sólida para realizar comparaciones con otras investigaciones. Un valor más bajo de MSE indica directamente un mejor rendimiento, lo que simplifica la comparación entre diferentes modelos o configuraciones de hiperparámetros.

Adicionalmente, hemos incorporado el Error Absoluto Medio (MAE) [2] y la Raíz del Error Cuadrático Medio (RMSE) [3] como métricas complementarias. El MAE proporciona una medida robusta de errores promedio, menos sensible a valores atípicos que el MSE, lo que puede ofrecer una visión más realista del rendimiento en algunas situaciones prácticas. Por su parte, el RMSE, al estar en la misma unidad de medida que las variables objetivo y penalizar más fuertemente los errores grandes (por su naturaleza cuadrática), ofrece una perspectiva valiosa sobre el impacto real de los errores del modelo. La combinación de MSE, MAE y RMSE permite una evaluación holística del modelo, asegurando que la precisión de las predicciones se entienda y se mejore de manera integral. Un valor bajo en estas tres métricas indica un modelo altamente preciso y confiable.

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2 \quad (1)$$

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}| \quad (2)$$

$$RMSE = \sqrt{MSE} \quad (3)$$

De esta manera, hemos decidido realizar validación cruzada de 5 folds y tomar los promedios del MSE, MAE y RMSE a lo largo de las divisiones, como nuestra estrategia de evaluación. La elección de esta metodología está respaldada en que la validación cruzada permite evaluar la

robustez y la capacidad de generalización del modelo, reduciendo el riesgo de sobreajuste a un conjunto de datos particular [11]. Además, dado que nuestro conjunto de datos es limitado, la validación cruzada nos ayuda a maximizar tanto el tamaño del conjunto de entrenamiento como del conjunto de prueba, lo cual resulta crucial para obtener una evaluación precisa del modelo sin desperdiciar datos valiosos.

La elección de 5 folds representa un equilibrio entre obtener una evaluación precisa y mantener una carga computacional razonable. Un número mayor de folds podría proporcionar una evaluación ligeramente más precisa, pero a expensas de un mayor costo computacional y tiempo de entrenamiento. Así mismo, la validación cruzada de 5 folds con el promedio del MSE como métrica es una práctica estándar en el campo de la predicción mediante aprendizaje automático. Esto facilita la comparación de los resultados con otros estudios y mantiene la consistencia metodológica en la investigación.

Un aspecto a tener en cuenta al abordar la validación cruzada es la naturaleza de los datos y cómo su distribución entre los diferentes conjuntos puede afectar la fiabilidad de la evaluación del modelo. Originalmente, optamos por una asignación aleatoria de datos en los 5 folds para garantizar que cada grupo contuviese una muestra representativa de los 5 días estudiados, ya que es una estrategia común en situaciones donde los datos son independientes e idénticamente distribuidos. Sin embargo, en contextos donde los datos son secuenciales o temporales, como en nuestro caso, tal aleatoriedad puede no ser adecuada.

Por lo tanto, tomamos la decisión de estratificar los datos por días (asignar cada día a un fold diferente) para entrenar en 4 días y evaluar en el día restante. Esta decisión metodológica se justifica por varias razones. Primero, preserva la integridad temporal de los datos, evitando el riesgo de que la información de un día específico influya en la predicción del mismo. Segundo, permite al modelo aprender de una secuencia temporal completa, reflejando más fielmente las condiciones bajo las cuales se realizarán las predicciones en la práctica. Tercero, nos brinda una comprensión más clara de cómo el modelo generaliza a datos no vistos de un día completo, lo cual es crítico para medir la confiabilidad del modelo en condiciones potencialmente desconocidas o cambiantes.

## 2.3. Modelo

Como línea base para el pronóstico de irradiación solar a corto plazo (de 30 minutos a 6 horas), implementamos un modelo híbrido que combina el análisis de las imágenes y datos numéricos expuestos en la sección 2.1. El componente central del modelo para el procesamiento de imágenes es VGG16, una red neuronal convolucional (CNN) conocida por su eficacia en el análisis de imágenes

[12]. Esta red consta de 16 capas como su nombre lo indica, incluyendo 13 capas convolucionales y 3 capas totalmente conectadas. Las capas convolucionales de VGG16 utilizan filtros de tamaño pequeño (3x3) y emplean la misma técnica de padding y stride, lo que le permite a la red aprender características más complejas en cada capa manteniendo un enfoque uniforme en toda la red. Tras cada bloque de capas convolucionales, se utiliza una capa de max pooling para reducir la dimensionalidad y aumentar la abstracción de las características. Las últimas tres capas de la red son totalmente conectadas y se encargan de la clasificación final. Antes de estas capas, se incorpora una capa de "flatten" para transformar los mapas de características 2D en un vector 1D. La red emplea la función de activación ReLU (Rectified Linear Unit) en todas las capas ocultas para introducir no linealidades y la última capa utiliza una función de activación softmax para producir una distribución de probabilidad sobre las distintas clases (ya que fue una red entrenada para clasificación) [12].

Sin embargo, en nuestra implementación utilizamos solamente el componente de extracción de características (capas convolucionales y de max pooling) de un modelo VGG16 preentrenado, disponible en la biblioteca torchvision. Durante la fase de propagación hacia adelante (forward), procesamos las imágenes de entrada a través de las capas convolucionales y, posteriormente, las aplanamos para su uso en la predicción de irradiación solar. Esta adaptación del modelo VGG16 nos permite aprovechar su capacidad analítica en un contexto diferente al de la clasificación de imágenes, centrándonos en la extracción efectiva de características relevantes para la predicción de irradiación solar.

Paralelamente, se desarrolló un modelo de red neuronal artificial (ANN por sus siglas en inglés) específicamente para el manejo de datos numéricos (hora, temperatura y humedad). Definimos una arquitectura secuencial con dos capas ocultas, donde la primera capa transforma los tres atributos de entrada en 128 nodos y la segunda capa en 64 nodos, ambas utilizando la función de activación ReLU.

Posteriormente se realiza la integración de estos dos componentes fusionando las características extraídas por el modelo VGG16 y los datos procesados por el modelo numérico. Se concatenan las salidas de ambos modelos, generando un vector combinado que luego pasa por dos capas adicionales de la red neuronal, con 256 y 1 nodo(s) respectivamente, intercaladas con la función de activación ReLU. El resultado es una salida única que representa la predicción de la irradiación solar. Esta arquitectura híbrida (ver figura 3), que combina eficientemente características visuales y datos numéricos, ofrece una aproximación novedosa y potencialmente más precisa para la predicción de la irradiación solar.

Posteriormente se plantearon mejoras en la red con el






Figure 3. Arquitectura del modelo híbrido VGG16-ANN

fin de refinar las predicciones. Un cambio importante fue incorporar datos históricos de irradiación (de 30 minutos y 1 hora previos) dentro del conjunto de datos numéricos, lo que requirió una adaptación en la primera capa de la red neuronal para acomodar estas entradas adicionales. Además, se optó por reemplazar la arquitectura VGG16 con ResNet18 [6] por su capacidad de evitar el problema del desvanecimiento del gradiente a través del uso de conexiones residuales que facilitan el flujo de información durante el entrenamiento. Además, al ser una red más ligera en términos de parámetros y computacionalmente menos intensiva, permite una experimentación más ágil y puede mejorar la precisión de las predicciones en nuestro contexto de uso.

ResNet18 comienza procesando la imagen de entrada a través de una capa convolucional inicial con un filtro de  $7 \times 7$  y un stride de 2. Esta operación es seguida por Batch Normalization y una activación ReLU, y luego por Max Pooling con un filtro de  $3 \times 3$  y un stride de 2 para reducir la dimensión espacial. La esencia de ResNet18 se encuentra en sus 8 bloques residuales, cada uno constando de dos capas convolucionales de  $3 \times 3$ . Estos bloques implementan las conexiones residuales que suman la entrada del bloque a su salida antes de aplicar la función de activación ReLU, permitiendo así que la red aprenda funciones de identidad de manera efectiva, lo que es crucial para el entrenamiento de redes profundas. A medida que la información fluye a través de la red, los filtros de las capas convolucionales incrementan sus canales desde 64, duplicándose en cada reducción dimensional significativa. En puntos estratégicos entre los bloques residuales, se incluyen capas convolucionales con stride de 2 para disminuir aún más las dimensiones espaciales. Antes de llegar a la capa final, ResNet18 emplea Global Average Pooling, lo que condensa los mapas de características a un valor promedio por canal. Finalmente, la red culmina con una capa totalmente conectada que transforma la salida del Global Average Pooling en tantos nodos como clases tenga el problema en cuestión, utilizando una función de activación Softmax para obtener la clasificación final [6].

Al igual que en el caso de VGG16, utilizamos una versión de ResNet18 que ha sido preentrenada en el con-

junto de datos de ImageNet y en lugar de utilizar toda la arquitectura de ResNet, tomamos todas las capas excepto la última capa totalmente conectada, por lo que las salidas del modelo no son las probabilidades de clase, sino un tensor de características que representa la información condensada y procesada extraída de las imágenes. Finalmente esta salida se aplanan en un vector unidimensional para ser concatenada con las características extraídas de la información numérica por la ANN. Una representación de este modelo final se muestra en la figura 4

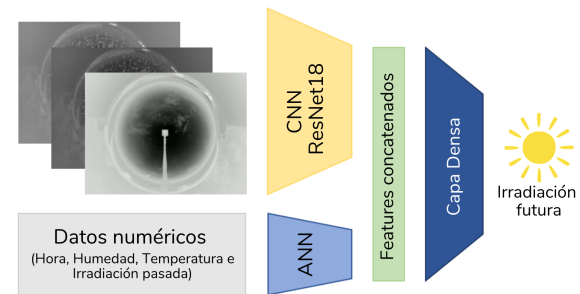


Figure 4. Representación del modelo híbrido ResNet18-ANN implementado

Para determinar las configuraciones óptimas de hiperparámetros de nuestro modelo, implementamos un proceso exhaustivo de búsqueda utilizando *sweep* a través de la herramienta Weights and Biases (wandb) [1]. Este enfoque nos permitió explorar sistemáticamente un amplio rango de combinaciones de hiperparámetros y evaluar su impacto en el rendimiento del modelo.

La configuración del *sweep* se basó en el método Bayesiano, una técnica sofisticada que utiliza modelos probabilísticos para seleccionar la próxima configuración de hiperparámetros a probar, basándose en los resultados anteriores. Este enfoque es particularmente eficiente para encontrar la mejor combinación en un espacio de hiperparámetros complejo y de alta dimensión.

Definimos la métrica de *avg val loss* como el criterio clave para la optimización, con el objetivo de minimizar esta métrica. El *avg val loss* representa la pérdida promedio de validación del modelo a lo largo de los 5 folds, por lo que es un indicador crucial de su precisión y capacidad de generalización.

Los hiperparámetros incluidos en el *sweep* fueron los siguientes:

1. *Tamaño del Lote (Batch Size)*: El tamaño del lote afecta la eficiencia y estabilidad del entrenamiento, así como la capacidad de generalización del modelo. Se probó una distribución uniforme de enteros para el tamaño del lote, variando entre 4 y 32.

2. *Número de Épocas (Epochs)*: Este valor determina la cantidad de veces que el algoritmo de aprendizaje trabajará a través de todo el conjunto de datos de entrenamiento. Se fijó en 15 épocas considerando entrenamientos previos de prueba que se realizaron para determinar cuando dejaba de disminuir la función de pérdida en validación.
3. *Gamma*: Este parámetro determina cuánto se reduce la tasa de aprendizaje en cada época. Un valor más cercano a 1 reduce la tasa de aprendizaje más lentamente, mientras que un valor más bajo reduce la tasa de aprendizaje más rápidamente. Se utilizó una distribución uniforme para gamma, con valores entre 0.4 y 0.95.
4. *Tasa de Aprendizaje (Learning Rate, lr)*: La tasa de aprendizaje es fundamental para controlar la rapidez con la que el modelo ajusta sus pesos en respuesta al error observado. Se exploraron valores en una distribución uniforme desde  $1e^{-05}$  hasta 0.001.

## 2.4. Procesamiento de imágenes

En esta sección, describimos en detalle los experimentos preliminares realizados para determinar el enfoque óptimo de preprocesamiento de imágenes, un paso crucial para mejorar la eficacia de nuestra red en la predicción de la irradiación solar utilizando imágenes de cielo abierto.

Inicialmente, abordamos la cuestión del formato de las imágenes. Dado que las imágenes originales se presentaban en un formato de 16 bits sin signo (uint16), exploramos la posibilidad de convertirlas a un formato de 8 bits sin signo (uint8). Esta conversión fue motivada por la hipótesis de que un formato de menor bit podría mejorar el desempeño de la red, posiblemente debido a una reducción en la complejidad de los datos y a una mejora en la eficiencia computacional.

Para abordar el desafío de la normalización de la intensidad en nuestras imágenes, inicialmente identificamos que los valores de intensidad se distribuían en rangos estrechos, lo cual podría comprometer la habilidad del modelo para diferenciar características significativas. Por esto, llevamos a cabo dos experimentos respecto a la normalización.

En primer lugar, aplicamos una normalización por imagen. Esta técnica consiste en ajustar el valor mínimo de intensidad de cada imagen individual a cero y el valor máximo a 255, lo que resulta en el uso completo del espectro de intensidades disponible. En segundo lugar, realizamos una normalización global que se llevó a cabo identificando los valores mínimos y máximos de intensidad en todo el conjunto de datos y utilizando estos valores globales para normalizar cada imagen. Esto asegura que la escala de intensidad sea coherente a través de todas las imágenes del

conjunto de datos, lo que puede ser particularmente beneficioso cuando las diferencias de iluminación y contraste entre imágenes son una característica significativa del dataset.

Por otro lado, experimentamos con la transformación del espacio de color de las imágenes. Pasamos de imágenes en color RGB a un espacio de color basado en mapas de colores (colormap). Este cambio se realizó para evaluar si un enfoque de color diferente podría capturar mejor las características relevantes para la predicción de irradiación solar.

Dada la naturaleza de 360 grados de las imágenes de cielo abierto, una proporción significativa de estas imágenes contiene información que podría considerarse no relevante para la tarea en cuestión. Por tanto, llevamos a cabo una transformación de las imágenes, pasándolas de coordenadas cartesianas a una representación polar, donde cada punto de la imagen original se mapea a un par de coordenadas polares con un ángulo y un radio, y luego se rota 90 grados para alinearse adecuadamente. Este proceso de "desdoblamiento" tenía como objetivo concentrarse en las áreas de interés y evaluar cómo esta modificación afectaba el rendimiento del modelo.




Figure 5. Visualización de los diferentes preprocesamientos. a) imagen en representación uint8, b) imagen normalizada según su propia escala, c) colormap sobre la imagen normalizada, d) desdoblamiento de la imagen normalizada

Así mismo, dado el amplio uso de las transformaciones a imágenes como método de aumento de datos en la visión por computador, se realizaron pruebas adicionales aplicando una serie de transformaciones a las imágenes para explorar su impacto en el rendimiento del modelo. Estas transformaciones incluían rotaciones aleatorias de hasta 15 grados, giros horizontales y verticales aleatorios y recorte dimensionado aleatorio con un tamaño de 224x224 píxeles y una escala que varía entre el 80% y el 100% del tamaño de la imagen.

Finalmente, llevamos a cabo un proceso de segmentación de las imágenes con el objetivo de identificar y aislar las nubes del resto de los elementos presentes en la imagen. Comenzamos por aplicar una serie de gradientes a la imagen original para resaltar las características de las nubes, lo que facilita su diferenciación del fondo. Luego, para eliminar artefactos no deseados como la barra de la cámara, aplicamos una máscara diseñada para cubrir y excluir selectivamente el artefacto, asegurando que solo las características relevantes sean consideradas en los pasos siguientes. Procedemos a aplicar un umbral de intensidad para separar las nubes en la imagen según su brillo, lo que

resulta en máscaras individuales que agrupamos para formar conjuntos contiguos de nubes. El paso final es multiplicar las máscaras agrupadas con la imagen original para "encender" aquellas regiones de la imagen que corresponden a las nubes y "apagar" todo lo demás. El resultado es una imagen (figura 6) en la que las nubes están claramente definidas y separadas del fondo, facilitando la evaluación y análisis de sus características.




Figure 6. Comparación de una imagen original y su respectiva imagen procesada con segmentación de nubes

## 2.5. Procesamiento de datos numéricos

La normalización de los datos en tareas de aprendizaje automático es un paso crítico, especialmente en modelos que son sensibles a la escala de las variables de entrada, como las redes neuronales. Sin normalización, las variables con rangos más amplios pueden dominar indebidamente el proceso de aprendizaje, lo que puede llevar a un rendimiento subóptimo del modelo. La normalización garantiza que cada variable contribuya equitativamente al aprendizaje, mejorando la precisión y la eficiencia del entrenamiento.

Tras observar en la tabla 1 que los rangos de las variables difieren significativamente entre sí, decidimos implementar dos métodos de normalización para mitigar este desequilibrio:

- **MinMaxScaler:** Este método reescala cada variable al rango de 0 a 1. Para lograr esto, MinMaxScaler resta el valor mínimo de cada variable de cada dato y luego lo divide por el rango (máximo - mínimo) de esa variable. La fórmula es:

$$x_{\text{scaled}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (4)$$

Donde  $x$  es el valor original,  $x_{\min}$  es el valor mínimo y  $x_{\max}$  es el valor máximo de la variable.

- **StandardScaler:** Este método transforma los datos de modo que su distribución tenga una media de 0 y una desviación estándar de 1. Al centrar los datos y reducir su varianza, StandardScaler hace que las características contribuyan de manera más uniforme al proceso de aprendizaje. Se calcula como:

$$x_{\text{scaled}} = \frac{x - \bar{x}}{s} \quad (5)$$

Aquí,  $\bar{x}$  es la media y  $s$  es la desviación estándar de la variable.

En nuestro caso, experimentamos con ambos para determinar cuál se alinea mejor con los requisitos de nuestro modelo y mejora su rendimiento en la tarea de aprendizaje automático. Los resultados de la normalización con cada uno de los métodos se muestra en la tabla 2.

Es importante resaltar que durante el tratamiento de los datos nos encontramos con la presencia de muy pocos valores faltantes (5 en total). Debido a que la cantidad de valores faltantes era mínima en comparación con el tamaño total del conjunto de datos, tomamos la decisión de eliminar los ejemplos que contenían estos valores faltantes en lugar de aplicar técnicas más complejas de imputación o manejo de datos incompletos.

## 2.6. Recursos computacionales

Para la realización de nuestros experimentos, utilizamos el sistema operativo Linux-5.15.0-89-generic-x86, una plataforma estable y ampliamente preferida en el ámbito de la computación científica y de datos, que se ejecuta sobre la versión de glibc 2.35. En cuanto al hardware, nuestro sistema contó con una CPU de 24 núcleos y 1 GPU del tipo NVIDIA TITAN X (Pascal).

## 3. Resultados

Como se detalló en la sección de metodología, nuestro enfoque inicial consistió en la implementación de un modelo híbrido que combina una Red Neuronal Convolutiva (CNN) y una Red Neuronal Artificial (ANN). Mediante el enfoque de *sweep* con wandb, pudimos explorar de manera eficiente y sistemática el espacio de hiperparámetros, lo que nos llevó a encontrar la configuración que mejoraba el rendimiento de nuestro modelo de manera significativa (ver tabla 3 y figura 7).




Figure 7. Ilustración del proceso de búsqueda de hiperparámetros en la plataforma wandb

A continuación se muestran los resultados de la experimentación acerca del debido procesamiento de los datos

Table 2. Datos numéricos después de aplicar normalización con MinMaxScaler y StandardScaler

	Hour		Temperature		Humidity		GHI	
	Standard	MinMax	Standard	MinMax	Standard	MinMax	Standard	MinMax
scaler	4180	4180	4180	4180	4180	4180	4180	4180
count	4180	4180	4180	4180	4180	4180	4180	4180
mean	-4.49E-16	0.501	-2.18E-16	0.477	-8.16E-17	0.496	-1.22E-16	0.404
std	1.000	0.288	1.000	0.271	1.000	0.300	1.000	0.295
min	-1.739	0.000	-1.760	0.000	-1.652	0.000	-1.370	0.000
max	1.729	1.000	1.932	1.000	1.676	1.000	2.024	1.000

Table 3. Hiperparámetros seleccionados para el entrenamiento de los modelos

Hiperparámetro	Valor
Batch Size	24
Epochs	15
Gamma	0.9138
Learning rate	0.0001

numéricos (Ver tabla 4 y tabla 5) y de las imágenes (tabla 6). Para estos experimentos se utilizó VGG16 como red convolucional y la estrategia de evaluación que divide los datos de manera aleatoria dentro de los folds de la validación cruzada.

Table 4. Comparación del desempeño del modelo según el formato de las imágenes

Experimento	MSE
uint16 (imagen original)	13.0020
uint8	<b>9.7670</b>

Table 5. Comparación del desempeño del modelo de acuerdo a los métodos de normalización de los datos numéricos

Experimento	MSE	MAE	RMSE
MinMaxScaler	<b>0.0017</b>	0.277	0.0414
StandardScaler	0.0145	0.0726	0.1194

Table 6. Comparación del desempeño del modelo al aplicar diferentes preprocesamientos a las imágenes

Experimento	MSE	MAE	RMSE
Normalización (por imagen)	0.0469	0.8530	0.2165
Normalización (por dataset)	0.0010	0.0186	0.0319
Colormap	0.0011	0.0213	0.0333
Transformaciones	0.1267	2.3044	0.3559
Desdoblamiento	<b>0.0010</b>	0.0194	0.0317

Basándonos en los resultados obtenidos en nuestras pruebas, se observó que cambiar la representación de los datos numéricos de un formato sin signo de 16 bits (uint16) a uno de 8 bits (uint8) condujo a un mejor desempeño del

modelo. Es importante destacar que, en esta fase del experimento, aún no se había aplicado una normalización a los datos numéricos. Por lo tanto, los errores reportados reflejan las escalas originales de la irradiación solar, sin ajustes por diferencias en la magnitud de los datos.

La implementación del MinMaxScaler para normalizar los datos numéricos resultó en una mejora notable del modelo. Así mismo, normalizar el conjunto de datos de imágenes utilizando los valores mínimos y máximos del conjunto completo, en lugar de hacerlo para cada imagen individualmente, también demostró ser beneficioso. Además, la técnica de desdoblamiento de las imágenes también mostró una mejora, aunque ligera, en el desempeño según la métrica del MSE.

Por otro lado, se realizaron cuatro experimentos para evaluar cómo la inclusión de diferentes tipos de información sobre la irradiación solar pasada afecta la precisión en la predicción de la irradiación solar para la media hora siguiente. Los tipos de datos considerados en estos experimentos fueron los siguientes:

- Hora: La hora exacta en que se tomó la imagen de cielo abierto. Este dato proporciona un contexto temporal que puede ser relevante para la predicción de la irradiación solar.
- Temp (Temperatura): La temperatura ambiental registrada en el momento de la captura de la imagen.
- Hum (Humedad): La humedad del ambiente al momento de tomar la imagen.
- GHI30 (Irradiación Solar - 30 Minutos): El valor de la irradiación solar registrada 30 minutos antes del momento cuya irradiación se desea predecir. Este dato proporciona una perspectiva histórica inmediata de la irradiación solar.
- GHI60 (Irradiación Solar - 60 Minutos): Similar a GHI30, pero refiriéndose a la irradiación solar registrada 60 minutos antes. Este valor ofrece un contexto histórico más amplio.

Las tablas 7 y 8 presentan los resultados del desempeño del modelo con diferentes combinaciones de estas variables



de entrada, utilizando VGG16 y ResNet18 como CNN, respectivamente. Para estos experimentos, se implementó la división de los folds de validación cruzada de manera ordenada (cada fold corresponde a un día de toma de datos).

Table 7. Comparación del desempeño del modelo al cambiar las entradas de la red

Experimentos VGG16	MSE	MAE	RMSE
Hora, temp, hum	0.0072	0.0657	0.0829
Hora, temp, hum, GHI30	0.0077	0.0666	0.0851
Hora, temp, hum, GHI60	<b>0.0070</b>	0.0638	0.0813
Hora, temp, hum, GHI30, GHI60	0.0081	0.0706	0.0877

Table 8. Comparación del desempeño del modelo al cambiar las entradas de la red usando ResNet18

Experimentos ResNet18	MSE	MAE	RMSE
Hora, temp, hum	0.0074	0.0680	0.0846
Hora, temp, hum, GHI30	<b>0.0069</b>	0.0662	0.0809
Hora, temp, hum, GHI60	0.0079	0.0694	0.0855
Hora, temp, hum, GHI30, GHI60	0.0072	0.0660	0.0822

A partir de estos resultados, se hace evidente la ventaja de incluir datos de irradiación solar pasada en el modelo, independientemente de la arquitectura de la CNN empleada. Sin embargo, cuando se emplea la arquitectura de VGG16 la inclusión de la variable GHI60 (irradiación solar reportada 60 minutos antes) demostró ser más beneficioso, mientras que para ResNet18, la variable GHI30 (irradiación solar reportada 30 minutos antes) proporcionó mejores resultados.

También evidenciamos que al eliminar la aleatoriedad al momento de dividir los datos en los folds de la validación cruzada, las métricas de evaluación aumentan. Sin embargo, entrenar el modelo en cuatro días y validar en el quinto asegura que la evaluación del desempeño sea robusta y que el modelo no se beneficie de fugas de información entre los conjuntos de entrenamiento y validación.

Durante estos experimentos, observamos diferencias significativas en el tiempo de ejecución entre los modelos que utilizaban distintas arquitecturas de redes neuronales convolucionales. Específicamente, los experimentos que emplearon la arquitectura VGG16 tardaron aproximadamente 48 minutos en completarse, mientras que el tiempo promedio de ejecución cuando se utilizó ResNet18 fue alrededor de 12 minutos. Esta variación en el tiempo de procesamiento refleja las diferencias inherentes en la complejidad computacional y la eficiencia de estas dos arquitecturas, siendo ResNet18 significativamente más rápida en comparación con VGG16 para nuestra tarea específica.

Por último, usando las mejores configuraciones obtenidas de los experimentos anteriores, se evaluó el desempeño del modelo al utilizar las imágenes segmentadas, obteniendo los resultados de la tabla 9.

A partir de los resultados anteriores, encontramos que

Table 9. Desempeño del modelo usando las imágenes segmentadas

	MSE	MAE	RMSE
Experimento segmentación	0.0098	0.0793	0.0959

contrario a nuestras expectativas iniciales, no se observó una mejora en las métricas de evaluación al utilizar las imágenes segmentadas. Esta situación sugiere que, en nuestro contexto específico, la segmentación de las imágenes no contribuyó significativamente al rendimiento del modelo, lo cual es un descubrimiento relevante que nos invita a reevaluar las estrategias de preprocesamiento de imágenes en futuros experimentos.

## 4. Discusión

Durante el proceso de desarrollo y optimización de nuestro modelo para la predicción de irradiación solar, tomamos decisiones fundamentadas en los resultados obtenidos en la sección anterior que se discuten a continuación.

Un hallazgo notable fue la mejora en el rendimiento del modelo al trabajar con imágenes en formato uint8 en comparación con uint16. Esta mejora puede atribuirse a que el formato uint8, ofrece una representación más compacta de la información de la imagen en comparación con el formato de 16 bits. Esto reduce la complejidad de los datos y puede facilitar el proceso de aprendizaje del modelo, permitiendo una extracción de características más eficiente y efectiva. Además, la mayoría de las redes neuronales preentrenadas y los algoritmos de procesamiento de imágenes están optimizados para trabajar con imágenes en este rango de 8 bits, lo que podría explicar la mejora en el rendimiento.

La superioridad observada del MinMaxScaler sobre el StandardScaler puede atribuirse a la naturaleza de los datos y a cómo los modelos de deep learning procesan la información. Al transformar los datos numéricos con MinMaxScaler en un rango fijo de 0 a 1, todas las variables tienen el mismo impacto relativo durante el entrenamiento inicial del modelo. Este rango uniforme es particularmente útil para redes neuronales, ya que los valores de entrada normalizados ayudan a mantener los gradientes en una escala manejable, previniendo problemas comunes como los gradientes que desaparecen o explotan durante el proceso de retropropagación. En contraste, el StandardScaler centra los datos alrededor de cero con una desviación estándar de uno, lo que resulta menos efectivo porque las escalas de las características usadas en la predicción difieren ampliamente.

La normalización de imágenes utilizando los valores mínimos y máximos de todo el dataset resulta más efectiva que la normalización individual por imagen por varias razones. Al aplicar un factor de normalización global, establecemos una base de referencia consistente para todas las

imágenes, lo que puede ser crucial cuando se trata de aprender características distintivas en tareas de predicción. Este enfoque asegura que las diferencias en la iluminación y el contraste entre imágenes no sean producto de variaciones aleatorias en la escala de intensidad, sino que reflejen diferencias reales en el contenido de las imágenes. Al utilizar los valores extremos del conjunto completo de datos, el modelo se entrena con una representación más homogénea de las características, lo que facilita la generalización a nuevos datos. Por el contrario, la normalización individual puede llevar a una inconsistencia en la representación de las características a través del conjunto de datos, ya que cada imagen se ajusta a su propia escala. Esto podría dificultar que el modelo aprenda patrones generales aplicables a todo el conjunto de datos y, por lo tanto, aumentando el error en las predicciones.

Los colormaps a menudo se utilizan para mejorar el contraste o resaltar características específicas dentro de las imágenes, pero en nuestro caso, esta técnica podría haber alterado o exagerado las características naturales de las imágenes, llevando a confusión en el modelo y dificultando la identificación de patrones relevantes para la predicción.

De manera similar, la observación de que las transformaciones aplicadas a las imágenes resultaron en un MSE notablemente más alto, sugiere que los recortes, las rotaciones y los giros aleatorios excluyeron y/o distorsionaron las características críticas en las imágenes de cielo abierto que son esenciales para predecir la irradiación solar. Las rotaciones y giros pudieron generar configuraciones de nubes y patrones de luz solar que no representan condiciones reales del cielo. Por otro lado, el recorte aleatorio pudo resultar en la exclusión de partes importantes de la imagen y por ende una pérdida de información crucial para la predicción. Además, al introducir variaciones artificiales en las imágenes, el modelo debe aprender a identificar características relevantes en un conjunto de datos más diverso y potencialmente más complejo. Esto puede aumentar la dificultad del aprendizaje, especialmente en nuestro caso, donde el modelo no tiene suficientes datos para generalizar correctamente a partir de estas variaciones.

Por otro lado, el desdoblamiento de las imágenes, que convierte las imágenes de un plano 2D a una representación en coordenadas polares, demostró ser beneficioso. Esta técnica puede ser particularmente útil para capturar la estructura radial de las nubes y la distribución de la luz solar, que son aspectos cruciales en la predicción de irradiación. Al desdoblar las imágenes, se facilita al modelo la captura de la simetría radial y los patrones de dispersión de la luz, que son más difíciles de discernir en el espacio cartesiano estándar. Por lo tanto, el desdoblamiento permitió que el modelo aprendiera de manera más efectiva la geometría y la dinámica de las formaciones nubosas en relación con la irradiación solar, lo que resultó en una mejora en las métricas

de evaluación como el MSE.

Incluir datos históricos de irradiación solar de hace 30 y 60 minutos de forma separada aporta beneficios significativos para la red. Los datos de 30 minutos previos ofrecen una visión cercana a la condición actual de irradiación, reflejando cambios recientes que pueden ser inmediatamente relevantes para la predicción a corto plazo. Por su parte, los datos de 60 minutos añaden una perspectiva más amplia, permitiendo que la red identifique tendencias a más largo plazo y patrones de cambio en la irradiación solar. Sin embargo, al introducir ambos conjuntos de datos simultáneamente, el modelo parece enfrentar dificultades, lo que podría estar relacionado con el fenómeno conocido como colinealidad, donde las variables altamente correlacionadas distorsionan la importancia que el modelo les asigna, resultando en un desempeño subóptimo. En otras palabras, la inclusión de múltiples variables temporales puede aumentar la complejidad del modelo sin proporcionar beneficios incrementales claros.

La superioridad de ResNet18 frente a VGG16 puede atribuirse a su arquitectura innovadora que permite que la información se propague a través de la red sin degradarse y aprender eficientemente características de nivel alto y bajo sin la saturación que a menudo acompaña a las redes más profundas. Además, ResNet18 está diseñada para ser más ligera en términos de parámetros que VGG16, lo que la hace menos propensa al sobreajuste y más rápida para entrenar y ejecutar, como se refleja en los tiempos de entrenamiento más cortos en nuestros experimentos.

Por último, el uso de imágenes con nubes segmentadas, aunque intuitivamente podría parecer beneficioso para la tarea de predicción de irradiación solar, no condujo a mejoras en las métricas de evaluación en nuestro estudio. Esta falta de mejora puede deberse a varios factores. Primero, la segmentación podría haber eliminado información contextual importante que las redes neuronales utilizan para aprender las características de las nubes en relación con su entorno. Segundo, si la segmentación no fue perfecta, podrían haberse introducido artefactos o ruido que confunden al modelo, deteriorando su capacidad para extraer patrones útiles. Además, la irradiación solar es el resultado de procesos complejos que involucran no solo la presencia de nubes sino también su densidad, altitud y la dispersión de la luz alrededor de ellas, información que podría perderse o simplificarse en exceso durante el proceso de segmentación.

De esta manera, nuestro estudio destaca la importancia de una cuidadosa selección y procesamiento de datos numéricos e imágenes, así como la elección de arquitecturas de red y la configuración de hiperparámetros para la predicción efectiva de la irradiación solar. Los resultados aquí discutidos proporcionan perspectivas valiosas para futuras investigaciones y aplicaciones en el campo de la predicción de la irradiación solar utilizando aprendizaje au-

tomático.

## 5. Conclusiones

En conclusión, nuestro enfoque mediante un modelo híbrido que integra ResNet para la extracción de características de imágenes y una red neuronal artificial (ANN) para el procesamiento de datos numéricos ha demostrado ser altamente efectivo, alcanzando un Error Cuadrático Medio (MSE) muy bajo de 0.00690. Este logro resalta la validez de nuestra metodología y la eficacia de las redes neuronales profundas en tareas complejas de predicción en el ámbito de la energía solar. La experimentación meticulosa y la optimización de hiperparámetros fueron fundamentales para afinar nuestro modelo y alcanzar este nivel de precisión. Los hallazgos de nuestro estudio, especialmente en cuanto a la importancia de la normalización de los datos y la selección estratégica de las características temporales, aportan valiosas contribuciones al campo de la predicción de irradiación solar. Estos avances no solo mejoran nuestra comprensión de los patrones subyacentes en los datos ambientales y de imágenes, sino que también establecen un precedente para futuras investigaciones y aplicaciones prácticas en la optimización de la generación de energía solar y la gestión de recursos energéticos.

Además, el valor agregado de nuestro proyecto radica en mejorar la eficiencia y la producción de energía solar de Enel, permitiéndoles una mejor planificación de sus recursos y aumentando su rentabilidad. Al predecir con precisión la irradiación solar, la empresa será capaz de planificar y optimizar el uso de sus recursos, como la capacidad de almacenamiento de energía y la gestión de la demanda. Esto permitirá a Enel aprovechar al máximo sus activos y aumentar su producción de energía solar, lo que a su vez mejorará su rentabilidad. Además, al proporcionar una herramienta precisa para la predicción de la irradiación solar, nuestro proyecto permitirá a Enel tomar decisiones informadas y estratégicas en su planificación de la energía solar, lo que podría llevar a reducciones significativas en costos y una mejor planificación a largo plazo.

## References

- [1] Lukas Biewald. Experiment tracking with weights and biases, 2020. Software available from wandb.com. [5](#)
- [2] Enel. Energía eléctrica: Enel colombia, 2018. [2](#)
- [3] ENEL. La planta fotovoltaica de el paso en colombia se ha puesto en marcha, Apr 2019. [2](#)
- [4] Sujan Ghimire, Ravinesh C Deo, David Casillas-Pérez, Sancho Salcedo-Sanz, Ekta Sharma, and Mumtaz Ali. Deep learning cnn-lstm-mlp hybrid fusion model for feature optimizations and daily solar radiation prediction. *Measurement*, 202:111759, 2022. [2](#)
- [5] Dolf Gielen, Francisco Boshell, Deger Saygin, Morgan D. Bazilian, Nicholas Wagner, and Ricardo Gorini. The role of renewable energy in the global energy transformation. *Energy Strategy Reviews*, 24:38–50, 2019. [1](#)
- [6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition, 2015. [5](#)
- [7] Munir Husein and Il-Yop Chung. Day-ahead solar irradiance forecasting for microgrids using a long short-term memory recurrent neural network: A deep learning approach. *Energies*, 12(10):1856, 2019. [2](#)
- [8] Yuhao Nie, Xiatong Li, Quentin Paletta, Max Aragon, Andea Scott, and Adam Brandt. Open-source ground-based sky image datasets for very short-term solar forecasting, cloud analysis and modeling: A comprehensive survey. *arXiv preprint arXiv:2211.14709*, 2022. [2](#)
- [9] Quentin Paletta and Joan Lasenby. Convolutional neural networks applied to sky images for short-term solar irradiance forecasting, 2020. [2](#)
- [10] Reuniwatt. Observación del cielo 24/7 con sky insight - reuniwatt: Previsión de la energía solar, Nov 2023. [3](#)
- [11] Cullen Schaffer. Selecting a classification method by cross-validation. *Machine learning*, 13:135–143, 1993. [4](#)
- [12] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014. [4](#)
- [13] Lilian Paola Umbarila Valencia, Freddy Leonard Alfonso Moreno, and Julio César Rivera Rodríguez. Importancia de las energías renovables en la seguridad energética y su relación con el crecimiento económico. *Revista de investigación agraria y ambiental*, 6(2):231–242, 2015. [1](#)
- [14] Haixiang Zang, Ling Liu, Li Sun, Lilin Cheng, Zhinong Wei, and Guoqiang Sun. Short-term global horizontal irradiance forecasting based on a hybrid cnn-lstm model with spatiotemporal correlations. *Renewable Energy*, 160:26–41, 2020. [2](#)
- [15] Hangxia Zhou, Yujin Zhang, Lingfan Yang, Qian Liu, Ke Yan, and Yang Du. Short-term photovoltaic power forecasting based on long short term memory neural network and attention mechanism. *Ieee Access*, 7:78063–78074, 2019. [2](#)